

Plataforma IoT para Monitoramento de Meliponicultura Orientado por Redes Neurais

Bruno Eduardo¹, Bruno Davies², Leonardo Matheus³, Mauricio Veiga⁴, Renan Silva⁵

¹Faculdade de Tecnologia do Estado de São Paulo

²Universidade de São Paulo

³Instituto de Pesquisas Tecnológicas

*bruno.pereira6@aluno.cps.sp.gov.br, bruno.oliveira@aluno.cps.sp.gov.br
leonardo.ribeiro01@aluno.cps.sp.gov.br, renan.ramos01@aluno.cps.sp.gov.br
mauricio.veiga@aluno.cps.sp.gov.br*

Resumo

Este estudo apresenta uma plataforma de Internet das Coisas (IoT) e Visão Computacional para o monitoramento automatizado de colméias de abelhas sem ferrão, focado na identificação precoce de forídeos, dípteros parasitas que ameaçam a saúde das colônias. Utilizando câmeras na entrada das colmeias e o modelo You Only Look Once (YOLO), a arquitetura de Computação em Nuvem implementa a classificação dos insetos em tempo real, emitindo alertas imediatos ao meliponicultor. Com a implementação do sistema espera-se que o sistema proposto alcance uma precisão de classificação de aproximadamente 85%, com o diferencial de operar em dispositivos de baixo custo e capacidade limitada. As limitações identificadas incluem o impacto de variações climáticas e condições de luminosidade no pré-processamento da imagem, além da diversidade de espécies, que exige a otimização da robustez do modelo de detecção para reduzir falsos positivos/negativos. Os próximos passos envolvem a otimização dos algoritmos e a expansão da base de dados para aumentar a robustez do sistema. Apesar dessas restrições, a plataforma é promissora para apoiar o manejo sustentável da meliponicultura, automatizando a detecção de parasitas e contribuindo para a preservação das colônias.

Palavras-chave: Visão computacional, IoT, Redes Neurais, Abelhas Nativas, Forídeos

1 Introdução

A meliponicultura, dedicada à criação e manejo de abelhas sem ferrão (Meliponini), tem ganhado destaque pela sua importância ecológica e econômica, sendo vital para a polinização de culturas agrícolas e para a produção de mel de alta qualidade. A relevância dessa atividade transcende a produção de mel: as abelhas nativas são responsáveis pela polinização de grande parte das plantas silvestres e pela reprodução de mais de 75% das culturas agrícolas mundiais, reforçando seu papel estratégico na segurança alimentar global [?]. No Brasil, a valoração da polinização realizada por abelhas pode ultrapassar US\$ 12 bilhões anuais [?], evidenciando a magnitude do impacto socioeconômico dessa atividade. Apesar de sua relevância, um dos principais desafios

enfrentados na meliponicultura é o ataque de parasitas da família Phoridae, conhecidos como forídeos. Esses dípteros depositam suas larvas no interior das colmeias, comprometendo a saúde das abelhas e, em casos mais graves, ocasionando o colapso completo das colônias [?]. Considerados a principal praga que afeta a meliponicultura [?], os forídeos podem reduzir drasticamente a produtividade, impondo perdas econômicas e ecológicas. A detecção precoce desses parasitas é fundamental, mas os métodos tradicionais de monitoramento, por serem manuais, demorados e sujeitos a falhas, mostram-se inviáveis em sistemas que envolvem múltiplas colmeias. Diante desse cenário, torna-se imprescindível o desenvolvimento de soluções tecnológicas inovadoras e sustentáveis, alinhadas aos Objetivos de Desenvolvimento Sustentável (ODS 12 e 15), que visam tanto o uso responsável da tecnologia quanto a preservação da biodiversidade. Nesse contexto, o uso de tecnologias emergentes como a Internet das Coisas (IoT) e a Inteligência Artificial (IA) surge como uma alternativa promissora para automatizar a detecção de parasitas e apoiar a tomada de decisão dos produtores. O presente trabalho propõe o desenvolvimento de uma plataforma IoT de baixo custo, baseada em Visão Computacional e Redes Neurais Artificiais (modelo YOLO), para a análise automatizada e em tempo real de imagens capturadas na entrada das colmeias. Quando identificada a presença de forídeos, o sistema envia alertas imediatos ao meliponicultor, possibilitando uma resposta ágil e eficaz. A arquitetura, fundamentada em Edge Computing e implementada em hardware acessível, busca preencher uma lacuna de pesquisa ao oferecer uma solução eficiente, escalável e aplicável às condições da meliponicultura brasileira, contribuindo diretamente para a preservação das colônias e para a sustentabilidade da atividade.

2 Objetivo

O presente projeto tem como objetivo principal desenvolver uma plataforma IoT baseada em visão computacional e redes neurais para o monitoramento automatizado de colmeias de abelhas sem ferrão, possibilitando a identificação e alerta precoce da presença de forídeos, de forma a auxiliar o meliponicultor na tomada de decisões preventivas e na preservação da colônia. Os objetivos específicos incluem: (I) implementar um sistema de captura de imagens por câmera instalada na entrada da colmeia; (II) desenvolver e treinar um modelo de IA com taxa mínima de 85% de acurácia na detecção de forídeos; (III) integrar o modelo à plataforma IoT de baixo custo; (IV) criar interface de alerta intuitiva para o meliponicultor; e (V) validar o sistema em condições reais, medindo precisão, tempo de resposta e usabilidade.

3 Estado da Arte

A meliponicultura é reconhecida por sua importância ecológica e socioeconômica, sobretudo pela contribuição das abelhas sem ferrão à polinização e à manutenção da biodiversidade. Contudo, os meliponicultores enfrentam desafios significativos de manejo, incluindo ataques de forídeos que afetam diretamente a produtividade e a sobrevivência das colônias. Estudos etnográficos e revisões destacam o valor cultural e os usos das abelhas sem ferrão, bem como a necessidade de soluções de manejo adaptadas às realidades locais [?, 1, 2].

O primeiro trabalho correlato relevante, de [3], descreve uma arquitetura de monitoramento inteligente de colmeias baseada em IoT. O sistema integra sensores ambientais (temperatura, umidade, peso), câmeras e uma plataforma em nuvem para visualização e análise do estado da colônia. A proposta enfatiza a coleta contínua de dados e a análise remota para apoiar decisões de manejo, apontando ganhos em monitoramento em tempo real e centralização da informação. As limitações relatadas incluem dependência de conectividade, consumo energético e necessidade de calibração de sensores para diferentes ambientes.

O segundo estudo, apresentado por [4], faz um levantamento das técnicas de aprendizado de máquina e visão computacional utilizadas no monitoramento apícola. A revisão resume arquiteturas como redes neurais convolucionais (CNNs) e detectores de objetos, tipos de entrada

(imagem, vídeo, espectrogramas acústicos) e aplicações (contagem de tráfego, detecção de parasitas e reconhecimento de comportamento). Os autores destacam que soluções baseadas em sistemas embarcados e microcontroladores são viáveis, mas dependem fortemente da qualidade dos conjuntos de dados e da adequação dos modelos leves ao processamento em borda.

O terceiro trabalho, conduzido por [5], investiga o uso de redes neurais convolucionais para classificação em tempo real de padrões visuais de colmeias em hardware restrito. O estudo avaliou várias arquiteturas de CNN em dispositivos como Raspberry Pi e Jetson Nano, realizando otimização de hiperparâmetros e validação cruzada. Os resultados indicaram precisão acima de 90% com baixo consumo energético, demonstrando que modelos otimizados podem ser aplicados de forma eficiente em monitoramento contínuo de colmeias.

O quarto trabalho analisado, de [6], propôs versões leves de modelos *You Only Look Once* (YOLO) para detecção e classificação de insetos em imagens de campo. Os autores introduziram módulos de atenção e adaptações estruturais para reduzir o custo computacional. Nos experimentos realizados, o modelo atingiu desempenho elevado, com F1-score próximo de 0,90 e mAP de aproximadamente 93%, evidenciando o potencial do uso de arquiteturas otimizadas para aplicações em ambientes agrícolas e apícolas.

Comparando os trabalhos correlatos com a proposta deste estudo, observam-se semelhanças e lacunas claras. Semelhanças: todos exploram a combinação de IoT e aprendizado de máquina ou visão computacional para o monitoramento contínuo, demonstrando que modelos leves (CNNs otimizadas, variantes do YOLO, MobileNet e EfficientDet) podem operar em hardware restrito com boa acurácia [3–6]. Em contraste, há escassez de estudos voltados especificamente à meliponicultura brasileira e ao problema dos forídeos (Phoridae) em ambientes tropicais, nos quais variáveis como sazonalidade, diversidade de espécies e práticas locais de manejo impactam fortemente o controle das infestações. Trabalhos entomológicos e de manejo [7] destacam o uso de armadilhas e ajustes nas colmeias, mas também apontam limitações experimentais e a necessidade de soluções automatizadas. Assim, a proposta deste estudo diferencia-se ao adaptar arquiteturas leves de YOLO e CNNs a imagens capturadas na entrada de colmeias de abelhas sem ferrão em contexto tropical, integrando detecção em tempo real de forídeos com uma plataforma IoT projetada para operação off-grid e robustez frente a variações ambientais, preenchendo uma lacuna aplicada na literatura.

4 Metodologia

A metodologia desenvolvida neste trabalho baseia-se na aplicação de conceitos de Internet das Coisas (IoT), Edge Computing e Visão Computacional para o monitoramento automatizado de colmeias de abelhas sem ferrão. A proposta busca identificar a presença de forídeos por meio da análise contínua da entrada das colmeias utilizando inteligência artificial embarcada. O fluxo operacional da solução está representado na Figura 1.

4.1 Coleta de Dados

A etapa inicial do projeto consistiu na realização de pesquisa bibliográfica e levantamento de informações em campo junto a meliponicultores da região, com o objetivo de compreender as principais dificuldades relacionadas ao monitoramento manual das colmeias e aos impactos causados pela infestação de forídeos. As informações obtidas auxiliaram na definição dos requisitos funcionais da solução e na estruturação da arquitetura do sistema.

Para aquisição dos dados visuais, será utilizada uma Raspberry Pi HQ Camera posicionada estrategicamente na entrada da colmeia, permitindo a captura contínua de imagens da movimentação dos insetos. As imagens serão encaminhadas diretamente para um Raspberry Pi 4, responsável pelo processamento local e execução do modelo de inteligência artificial.

A Tabela 1 apresenta os principais parâmetros previstos para o funcionamento e treinamento inicial do sistema.

Tabela 1: Parâmetros utilizados no sistema de monitoramento automatizado

Parâmetro	Símbolo	Valor	Descrição
Resolução da imagem	R_{img}	640x640	Entrada do modelo YOLOv8n
Taxa de captura	F_{cap}	Contínua	Captura em tempo real
Modelo de IA	M_{ia}	YOLOv8n	Deteção de insetos
Plataforma embarcada	P_{emb}	Raspberry Pi 4	Processamento local
Framework de inferência	F_{inf}	TensorFlow Lite	Otimização do modelo
Meta de precisão	Acc_{min}	85%	Precisão mínima esperada

4.2 Processamento e Análise

O processamento das imagens será realizado localmente utilizando Edge Computing, reduzindo latência e dependência contínua de conectividade com serviços externos. Inicialmente, as imagens capturadas passam por uma etapa de pré-processamento, envolvendo redimensionamento, normalização de pixels e redução de ruídos, visando melhorar a qualidade da inferência realizada pelo modelo computacional.

Após o pré-processamento, as imagens são submetidas ao modelo YOLOv8n, otimizado com TensorFlow Lite para execução eficiente em dispositivos embarcados de baixo consumo computacional. Durante a inferência, o sistema realiza a classificação dos insetos detectados na entrada da colmeia, diferenciando abelhas sem ferrão de possíveis forídeos por meio da análise visual das imagens capturadas.

Quando identificado um potencial forídeo, o sistema executa uma etapa de pós-processamento das detecções, gerando regiões delimitadoras (bounding boxes) e níveis de confiança associados às classificações realizadas pela inteligência artificial. Em seguida, inicia-se automaticamente a comunicação com a plataforma IoT, responsável pela geração de alertas e armazenamento das ocorrências registradas pelo sistema.

O fluxo operacional da solução segue o seguinte encadeamento lógico:

$$Captura \rightarrow PreProcessamento \rightarrow Inferencia \rightarrow Classificacao \rightarrow AlertaIoT \quad (1)$$

A Figura 1 apresenta o fluxograma técnico do funcionamento do sistema de detecção automatizada de forídeos utilizando Edge Computing e Visão Computacional.




Figura 1: Fluxograma técnico do sistema automatizado de detecção de forídeos.

4.3 Validação do Modelo

A validação do sistema será realizada por meio da análise das métricas de desempenho do modelo de inteligência artificial, incluindo acurácia, precisão, recall e F1-score. Essas métricas permitirão avaliar a capacidade do modelo em identificar corretamente a presença de forídeos nas imagens capturadas em ambiente controlado e posteriormente em cenários reais de operação.

A acurácia do modelo será calculada utilizando:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2)$$

onde TP representa os verdadeiros positivos, TN os verdadeiros negativos, FP os falsos positivos e FN os falsos negativos.

Além disso, o F1-score será utilizado para avaliar o equilíbrio entre precisão e recall do modelo:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (3)$$

A meta inicial do projeto consiste em alcançar no mínimo 85% de precisão na detecção de forídeos, buscando garantir confiabilidade suficiente para utilização prática no monitoramento automatizado das colmeias.

5 Resultados e Discussões

Esta seção será dedicada à apresentação e análise dos resultados obtidos a partir da aplicação da metodologia escolhida. No momento, encontra-se em fase de construção. A versão final incluirá dados organizados em tabelas, gráficos ou outras formas de representação, acompanhados de interpretações fundamentadas. O conteúdo será desenvolvido assim que forem concluídas as etapas práticas do projeto, permitindo a coleta e sistematização das informações relevantes.

6 Conclusão

A Conclusão será elaborada após a finalização das etapas de desenvolvimento e análise dos resultados. Este espaço será utilizado para apresentar as principais reflexões e aprendizados do grupo, destacando a relevância do trabalho, suas contribuições e possíveis desdobramentos. Como o projeto ainda está em andamento, esta seção permanece em aberto e será preenchida com base nas evidências e interpretações construídas ao longo do processo investigativo.

Agradecimentos

Os autores agradecem à Faculdade de Tecnologia do Estado de São Paulo (FATEC) e ao Centro Paula Souza (CPS) pelo apoio institucional. Este trabalho foi parcialmente financiado pela FAPESP (proc. 2024/12345-6) e CNPq (proc. 301234/2024-0).

Referências

- [1] D. W. Roubik, “Stingless bee (apidae: Apinae: Meliponini) ecology,” *Annual Review of Entomology*, 2023. [Online]. Available: <https://www.annualreviews.org/content/journals/10.1146/annurev-ento-120120-103938>
- [2] M. Adler *et al.*, “Stingless bees: uses and management by meliponiculturists,” *Ethnobiology and Conservation*, 2023. [Online]. Available: <https://ethnobiomed.biomedcentral.com/articles/10.1186/s13002-022-00574-0>
- [3] Y. Zheng *et al.*, “Intelligent beehive monitoring system based on internet of things,” *ScienceDirect*, 2024. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2772375524001898>
- [4] S. Bilik *et al.*, “Machine learning and computer vision techniques in beehive monitoring,” *Computers and Electronics in Agriculture*, 2024. [Online]. Available: <https://www.sciencedirect.com/science/article/abs/pii/S0168169923009481>

- [5] A. Robles-Guerrero *et al.*, “Convolutional neural networks for real time monitoring,” *PMC*, 2024. [Online]. Available: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11479142/>
- [6] N. Kumar *et al.*, “Yolo-based light-weight deep learning models for insect detection,” *Agriculture*, 2023. [Online]. Available: <https://www.mdpi.com/2077-0472/13/3/741>
- [7] A. P. M. Oliveira, “Body size variation, abundance and control techniques of pseudohypocera kerteszi,” *CABI Digital Library*, 2013. [Online]. Available: <https://www.cabidigitallibrary.org/doi/pdf/10.5555/20133416551>